4. Основные понятия математической статистики

4.1. Предмет математической статистики

Математическая статистика — это наука, которая методами теории вероятностей на основании результатов наблюдений изучает закономерности в массовых случайных явлениях. Математическая статистика (не путать со статистикой — разделом экономической теории) указывает способы сбора и группировки статистических данных (результатов наблюдений), разрабатывает методы их обработки для оценки характеристик распределения, для установления зависимости случайной величины от других, для проверки статистических гипотез о виде распределения или значениях его параметров. Математическая статистика возникла и развивалась параллельно с теорией вероятностей.

4.2. Генеральная совокупность и выборка

Значительная часть математической статистики связана с необходимостью описать большую совокупность объектов. Ее называют генеральной. Если *генеральная совокупность* слишком многочисленна, или ее объекты труднодоступны, или имеются другие причины, не позволяющие изучить все объекты, прибегают к изучению какой-то части объектов. Эта выбранная для полного изучения часть называется *выборкой*. Необходимо, чтобы выборка наилучшим образом представляла генеральную совокупность, т.е. была *репрезентативной* (*представительной*). Если генеральная совокупность мала или совсем неизвестна, не удается предложить ничего лучшего, чем чисто случайный выбор.

Пример 4.1. *Пусть необходимо оценить качество изделий, выпускаемых определенным цехом машиностроительного предприятия. Для этого выбирают партию изделий и подвергают их контролю с целью дефектирования. Доля бракованных изделий для выбранной партии распространяется затем на всю продукцию цеха.*

Здесь генеральная совокупность — все изделия, выпускаемые цехом, выборка — отобранные для проверки изделия.

Пример 4.2. *Пусть необходимо оценить будущий урожай пшеницы. Для этого выбирают небольшой участок поля, например один квадратный метр, и подсчитывают число зерен во всех колосках и их массу. Приближенно весь урожай равен площади поля в метрах, умноженной на массу*

зерен, собранную с данного участка. Здесь генеральная совокупность — весь ожидаемый урожай, а выборка — урожай, собранный с одного квадратного метра. Если выбрать «плохой» участок (например, близко к краю поля), то оценка урожая будет заниженной. Если же участок имеет преимущества перед другими (например, лучше освещается солнцем), то оценка урожая будет завышенной.

Пример 4.3. *Производится социологическое исследование с целью прогноза результатов предстоящих выборов мэра города.*

Здесь генеральная совокупность — все избиратели города, а выборка — число опрошенных респондентов.

Большое значение имеет способ, которым получена выборка. Ошибки при выборе способа отбора приводят к тому, что выборка становится нерепрезентативной.

Если в качестве респондентов взять, например, сто первых встречных с 10 до 12 часов дня, то социологи узнают мнение не всех слоев населения, а только домохозяек, направляющихся в это время за покупками.

Будем проводить испытания и в каждом из них фиксировать значения, которые приняла случайная величина ξ. В результате n испытаний получим выборку n значений, образующих простую статистическую совокупность наблюдений.

Определение 4.1. *Количество наблюдений n называется* ***объемом выборки****.*

При большом числе наблюдений (сотни, тысячи) простая статистическая совокупность перестает быть удобной формой записи статистического материала — она становится слишком громадной. Для более экономичной записи наблюдаемые значения группируют.

Пусть в выборке значение x_1 наблюдалось m_1 раз, x_2 — m_2 раз, ..., x_k — m_k раз и $\sum_{i=1}^{k} m_i = n$ — объем выборки.

Определение 4.2. *Наблюдаемые значения x_i называют* ***вариантами****, а их последовательность, записанную в возрастающем порядке —* ***вариационным рядом****. Числа наблюдений $m_1, m_2, \ldots, m_k$ называют* ***частотами****.*

Разность $max(x_i) - min(x_i)$ называется ***размахом вариационного ряда****.*

Статистическим распределением выборки называют перечень вариант и соответствующих им частот — табл. 4.1.

Таблица 4.1

Статистическое распределение			
варианты x_i	x_1	$\dots$	x_k
частоты m_i	m_1	$\dots$	m_k

4.3. Эмпирическая функция распределения и гистограмма

С каждым испытанием, в котором наблюдается некоторая случайная величина ξ, можно связать случайное событие $\xi = x_i$, но иногда удобнее рассматривать событие $\xi < x_i$.

Определение 4.3. ***Эмпирической*** *(статистической)* ***функцией распределения*** *случайной величины ξ называется функция $F^*(x)$, которая при каждом x равна относительной частоте события $\xi < x$, т.е. отношению m_x — числа наблюдений меньших x к объему выборки n:*

$$F^*(x) = P^*(\xi < x) = \frac{m_x}{n}\ .$$

Пример 4.4. *Построить эмпирическую функцию распределения для данной выборки:*

Варианты x_i	*1*	*4*	*6*	*7*	*8*	*10*
Частоты m_i	*5*	*10*	*15*	*5*	*10*	*5*

◀Объем выборки n равен 5+10+15+5+10+5=50. Наименьшая варианта равна 1, следовательно $F^*(x) = 0$ при $x \leqslant 1$. Значение $x < 4$, а именно $x = 1$ наблюдалось 5 раз, следовательно $F^*(x) = \frac{5}{50} = 0{,}1$ при $1 < x \leqslant 4$. Значения $x < 6$, а именно $x = 1$ и $x = 4$, наблюдались 5+10=15 раз, следовательно $F^*(x) = \frac{15}{50} = 0{,}3$ при $4 < x \leqslant 6$. Аналогично получаем $F^*(x) = \frac{30}{50} = 0{,}6$ при $6 < x \leqslant 7$ и т.д. Так как 10 — наибольшая варианта, $F^*(x) = 1$ при $x > 10$.

$$F^*(x) = \begin{cases} 0 & \text{при} \quad x \leqslant 1, \\ 0{,}1 & \text{при} \quad 1 < x \leqslant 4, \\ 0{,}3 & \text{при} \quad 4 < x \leqslant 6, \\ 0{,}6 & \text{при} \quad 6 < x \leqslant 7, \\ 0{,}7 & \text{при} \quad 7 < x \leqslant 8, \\ 0{,}9 & \text{при} \quad 8 < x \leqslant 10, \\ 1 & \text{при} \quad x > 10. \end{cases}$$

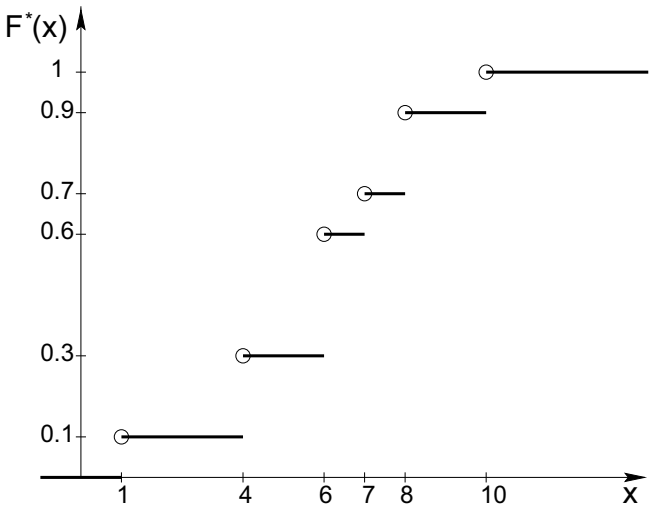


Рисунок 29. *Эмпирическая функция распределения*

График найденной функции представлен на рис. 29.
Из определения $F^*(x)$ вытекают ее свойства:

1) $0 \leqslant F^*(x) \leqslant 1$;

2) $F^*(x)$ — ступенчатая неубывающая функция;

3) если x_1 — наименьшая, а x_k — наибольшая варианты, то $F^*(x) = 0$ при $x \leqslant x_1$ и $F^*(x) = 1$ при $x > x_k$.

Гистограмма представляет выборку более наглядно. Для построения гистограммы разделим весь диапазон наблюдений на s интервалов вида $(a_{j-1}; a_j]$ и определим количество наблюдений m_j, попавших в j-й интервал. Относительная частота наблюдений, попавших в j-й интервал, равна $P_j^* = \dfrac{m_j}{n}$ $(m_1 + \ldots + m_s = n)$, сумма всех относительных частот, очевидно, равна единице. Для построения гистограммы по оси ординат откладываются значения $\dfrac{P_j^*}{\Delta a_j} = \dfrac{m_j}{n \cdot (a_j - a_{j-1})}$. Полученная фигура, состоящая из прямоугольников, называется гистограммой относительных частот. Площадь каждого прямоугольника равна относительной частоте наблюдений, попавших в данный интервал. Для данных примера 4.4 получаются следующие значения:

N п/п	a_{j-1}	a_j	m_j	$P_j^* = \dfrac{m_j}{n}$	$\dfrac{P_j^*}{\Delta a_j}$
1	0	3	5	0.1	1/30
2	3	6	25	0.5	5/30
3	6	9	15	0.3	3/30
4	9	12	5	0.1	1/30

Получившаяся гистограмма представлена на рис. 30.

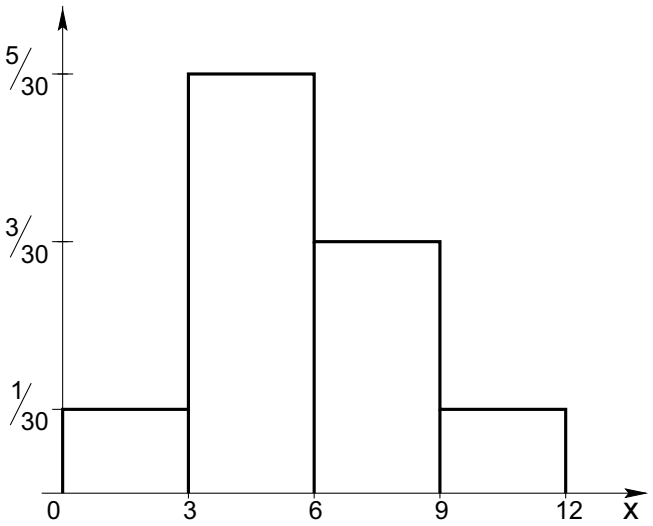


Рисунок 30. *Гистограмма относительных частот*

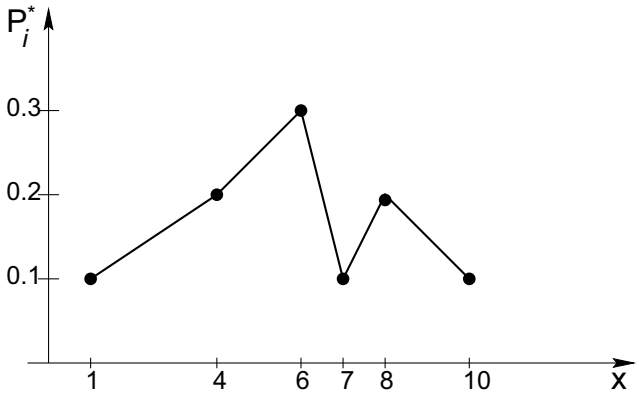


Рисунок 31. *Полигон относительных частот*

Другим наглядным способом представления распределения является полигон относительных частот. Для его построения по оси абсцисс откладываются варианты, а по оси ординат — относительные частоты (рис. 31), и полученные точки соединяются ломаной линией.

Для выборки из генеральной совокупности значений непрерывной случайной величины гистограмма является статистическим аналогом плотности распределения, а для дискретной случайной величины полигон относительных частот является статистическим аналогом многоугольника вероятностей. При увеличении объема выборки эти статистические характеристики в определенном смысле приближаются к своим теоретическим аналогам.

Замечание 4.1. *Наряду с гистограммой и полигоном относительных частот иногда рассматривают соответственно гистограмму и полигон частот, отличающиеся масштабом по оси ординат — все значения по оси ординат умножаются на n — объем выборки. Понятно, что форму получаемых фигур это не изменяет.*

4.4. Числовые характеристики статистического распределения

Статистическая функция распределения и гистограмма являются полными характеристиками результатов наблюдения случайной величины в данной серии испытаний. Однако иногда целесообразно ограничиться более простой, хотя и неполной характеристикой распределения.

Простейшей характеристикой распределения является *выборочное среднее*, которое для простой статистической совокупности вычисляется по формуле:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i. \tag{4.1}$$

Если данные сгруппированы, то:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{k} m_i \cdot x_i. \tag{4.2}$$

Иными словами, выборочное среднее представляет собой среднее взвешенное значение, причем веса равны соответствующим частотам.

Для характеристики разброса значений случайной величины относительно ее среднего значения используется *выборочная дисперсия*

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \overline{(x - \bar{x})^2} \tag{4.3}$$

для простой совокупности и

$$S^2 = \frac{1}{n}\sum_{i=1}^{k} m_i(x_i - \bar{x})^2 \tag{4.4}$$

для сгруппированного распределения (распределения представленного в виде Таблица 4.1).

Очевидно, выборочная дисперсия имеет ту же размерность, что и квадрат случайной величины. Практически удобно пользоваться величиной, имеющей ту же размерность, что и данная случайная величина.

Для этого достаточно из дисперсии извлечь квадратный корень.

Эта величина

$$S = \sqrt{S^2} \tag{4.5}$$

называется *выборочным средним квадратическим отклонением* (СКО).

На практике вместо формулы (4.3) бывает удобнее применять другую:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - (\bar{x})^2 = \overline{x^2} - \overline{x}^2 \tag{4.6}$$

для простой совокупности и

$$S^2 = \frac{1}{n}\sum_{i=1}^{k} m_i x_i^2 - (\bar{x})^2 \tag{4.7}$$

для сгруппированного распределения.

Докажем формулу (4.6):

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i^2 - 2x_i\bar{x} + \bar{x}^2) =$$

$$= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - 2\bar{x}\frac{1}{n}\sum_{i=1}^{n} x_i + \bar{x}^2 = \overline{x^2} - 2\bar{x}\cdot\bar{x} + \bar{x}^2 = \overline{x^2} - \overline{x}^2.$$

Определение 4.4. ***Модой*** *статистического распределения (обозначается M_O) называется значение, которое наиболее часто встречается в исследуемой выборке.*

Для простой статистической совокупности мода вычисляется простым подсчетом. Например, для вариационного ряда $\{2, 2, 4, 5, 5, 5, 5, 6, 6, 7\}$, $M_O = 5$, т.к. значение 5 встречается чаще других.

Для сгруппированной выборки значение для моды необходимо аппроксимировать. Формула будет приведена ниже (4.8).

Статистические распределения, которые имеют несколько наиболее часто встречающихся значений, называются ***мультимодальными*** или ***полимодальными***.

Например, для вариационного ряда: $\{1, 2, 2, 3, 4, 5, 5, 6, 6, 7\}$, модами будут три значения $M_O = \{2, 5, 6\}$.

Определение 4.5. ***Медианой*** *(M_e) называется значение, которое разбивает выборку на две равные части. Половина наблюдений лежит ниже (левее) медианы, а другая половина выше (правее) медианы.*

Для простой статистической совокупности медиана вычисляется следующим образом. Исследуемая выборка $\{x_i\}$ сортируется в порядке не убывания значений элементов. Далее, если объем выборки – нечетное число, то $M_e = x_{(n+1)/2}$, иначе $M_e = \big(x_{n/2} + x_{n/2+1}\big)/2$.

Например, для вариационного ряда $\{1, 3, 5, 7, 9, 9, 12\}$ медиана равна четвертому элементу $M_e = 7$, а для вариационного ряда $\{1, 3, 5, 7, 9, 12\}$ медиана равна среднему арифметическому третьего и четвертого элементов $M_e = (5 + 7)/2 = 6$.

Пример 4.5. *Выборка задана в виде распределения частот:*

x_i	*1*	*5*	*9*	*12*	*16*	*18*
m_i	*5*	*10*	*30*	*25*	*22*	*8*

Найти моду, медиану, выборочное среднее и выборочную дисперсию.

◀Здесь объем выборки

$$n = 5 + 10 + 30 + 25 + 22 + 8 = 100.$$

Мода равна 9, так значение $x_3 = 9$ встречается максимальное число раз – $m_3 = 30$. Медиана равна 12, так как, если расположить все элементы выборки в виде неубывающий последовательности ее значений, то 50 и 51 значение будут равны 12.

Найдем выборочное среднее $\bar{x}$.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{k} m_i \cdot x_i = 0{,}01 \cdot \big(5 \cdot 1 + 10 \cdot 5 + 30 \cdot 9 + 25 \cdot 12 + 22 \cdot 16 + 8 \cdot 18\big) = 11{,}21.$$

$$\overline{x^2} = \frac{1}{n}\sum_{i=1}^{k} m_i \cdot x_i^2 = 0{,}01 \cdot \big(5 \cdot 1^2 + 10 \cdot 5^2 + 30 \cdot 9^2 + 25 \cdot 12^2 + 22 \cdot 16^2 + 8 \cdot 18^2\big) = 145{,}09.$$

Выборочная дисперсия:

$$S^2 = \overline{x^2} - (\bar{x})^2 = 145{,}09 - 11{,}21^2 = 19{,}426.$$

▶

Для выборки, представленной в виде сгруппированного по интервалам распределения, значение моды аппроксимируется в некоторую точку модального интервала (внутри которого находится максимальное значение):

$$M_0 = X_0 - h\frac{f_{mo} - f_{mo-1}}{f_{m0-1} - 2f_{mo} + f_{mo+1}}, \tag{4.8}$$

где X_0 — нижнее значение модального интервала; $f_{mo}, f_{mo-1}, f_{mo+1}$ — значение частот в модальном, предыдущем и следующем интервалах, соответственно; h — размах модального интервала.

Для выборки, представленной в виде сгруппированного по интервалам распределения, значение медианы аппроксимируется в некоторую точку M_e

медианного интервала по формуле:

$$M_e = X_0 + h\frac{0{,}5\sum\limits_{k=1}^{s} f_k - \sum\limits_{k=1}^{m_e-1} f_k}{f_{me}}, \tag{4.9}$$

где X_0 — нижняя граница интервала, в котором находится медиана (медианный интервал); f_{me} — значение частоты в медианном интервале; h — размах медианного интервала.

Пример 4.6. *Проведена выборка из* $n = 100$ *значений* $\{x_1, x_2, \ldots, x_n\}$ *некоторой непрерывной случайной величины* ξ. *Для удобства обработки результатов, полученные значения, заключенные на отрезке* $[0; 30]$, *разбили на 6 интервалов постоянной длины и поместили в таблицу.*

i	1	2	3	4	5	16
$(a_{i-1}; a_i]$	[0; 5]	(5; 10]	(10; 15]	(15; 20]	(20; 25]	(25; 30]
m_i	5	10	30	25	22	8

По полученной выборке, заключенной в таблицу, аппроксимировать моду, медиану, выборочное среднее, выборочное среднеквадратическое отклонение (СКО) и функцию распределения $F(x)$ *непрерывной случайной величины* ξ.

◀ Аппроксимируем значение моды случайной величины ξ. Здесь третий интервал является модальным $X_0 = 10, f_{mo} = 30, f_{mo-1} = 10, f_{mo+1} = 25$, $h = 5$.

$$M_0 = 10 - 5 \cdot \frac{30 - 10}{10 - 2 \cdot 30 + 25} = 14.$$

Аппроксимируем значение медианы случайной величины ξ.
Здесь четвертый интервал – медианный $X_0 = 15, f_{me} = 25, h = 5$.

$$M_e = 15 + 5 \cdot \frac{50 - (5 + 10 + 30)}{25} = 16.$$

Для вычисления выборочных характеристик значения частот группируются в центре интервалов, значение которых равны:
$D = \{2{,}5; 7{,}5; 12{,}5; 17{,}5; 22{,}5; 27{,}5\}$.

Находим выборочное среднее:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{k} m_i d_i =$$

$$= \frac{1}{100}(5 \cdot 2{,}5 + 10 \cdot 7{,}5 + 30 \cdot 12{,}5 + 25 \cdot 17{,}5 + 22 \cdot 22{,}5 + 8 \cdot 27{,}5) = 16{,}15.$$

Выборочную дисперсию находим по формуле: $S^2 = \overline{x^2} - (\bar{x})^2$: $\overline{x^2} = \dfrac{1}{n}\sum\limits_{i=1}^{k} m_i d_i^2 =$
$= \dfrac{1}{100}(5 \cdot 2{,}5^2 + 10 \cdot 7{,}5^2 + 30 \cdot 12{,}5^2 + 25 \cdot 17{,}5^2 + 22 \cdot 22{,}5^2 + 8 \cdot 27{,}5^2) = 301{,}25.$
Выборочное СКО:

$$S^2 = \overline{x^2} - (\bar{x})^2 = 301{,}25 - 16{,}15^2 = 40{,}4275.$$

$$S = \sqrt{S^2} = \sqrt{40{,}4275} \approx 6{,}358.$$

Для аппроксимации функции распределения будем считать, что случайная величина на каждом i-том интервале распределена равномерно. Следовательно, на каждом интервале функция распределения является линейной. Находим массив относительных частот:
$P_i^* = m_i/n = \{0{,}05; 0{,}1; 0{,}3; 0{,}25; 0{,}22; 0{,}08\}$ и массив накопленных относительных частот: $Q_i = \sum\limits_{k=1}^{i} P_k^* = \{0; 0{,}05; 0{,}15; 0{,}45; 0{,}7; 0{,}92; 1\}, i = 0, 1, \ldots, 6.$

По точкам с координатами: $M(a_i; Q_i), i = 0, 1, \ldots, 6$, проводим кусочно-линейную кривую. Уравнение эмпирической функции распределения имеет вид

$$F^*(x) = \begin{cases} 0 & \text{при} \quad x \leqslant 0, \\ 0{,}01x & \text{при} \quad x \in (0, 5], \\ 0{,}05 + 0{,}02(x-5) & \text{при} \quad x \in (5, 10], \\ 0{,}15 + 0{,}06(x-10) & \text{при} \quad x \in (10, 15], \\ 0{,}45 + 0{,}05(x-15) & \text{при} \quad x \in (15, 20], \\ 0{,}7 + 0{,}044(x-20) & \text{при} \quad x \in (20, 25], \\ 0{,}92 + 0{,}016(x-25) & \text{при} \quad x \in (25, 30], \\ 1 & \text{при} \quad x > 30. \blacktriangleright \end{cases}$$

4.5. Точечные оценки параметров распределения

Выборочное среднее, выборочная дисперсия и СКО являются примерами точечных оценок параметров распределения.

Определение 4.6. ***Точечной оценкой*** $\widetilde{a}_n$ *неизвестного параметра* a *распределения случайной величины* ξ *называется функция от наблюдений:*

$$\widetilde{a}_n = \widetilde{a}(x_1, \ \ldots, x_n).$$

Для изучения свойств этой оценки ее рассматривают как функцию от n независимых случайных величин $\xi_1, \ldots, \xi_n$, имеющих такое же распределение, что и ξ; $x_1, \ldots, x_n$ в этом случае рассматриваются как наблюдения над этими случайными величинами: x_i — полученное значение ξ_i, $i = 1, 2, \ldots, n$. Сама оценка $\widetilde{a}_n$ в этом случае является случайной величиной.

Перечислим свойства точечной оценки $\widetilde{a}_n$, которые могут считаться «хорошими».

Определение 4.7. *Оценка $\widetilde{a}_n$ называется* ***состоятельной****, если при $n \to \infty$ она сходится по вероятности к оцениваемому параметру a:*

$$\lim_{n\to\infty} P(|\widetilde{a}_n - a| < \varepsilon) = 1 \text{ для } \forall\ \varepsilon > 0.$$

Определение 4.8. *Оценка $\widetilde{a}_n$ называется* ***несмещенной****, если ее математическое ожидание равно оцениваемому параметру a:*

$$M(\widetilde{a}_n) = a.$$

Иногда точечные оценки обладают более слабым свойством: их смещение $M(\widetilde{a}_n) - a$ стремится к нулю при $n \to \infty$. Такие оценки называются асимптотически несмещенными.

Определение 4.9. *Несмещенная оценка $\widetilde{a}_n$ называется* ***эффективной****, если ее дисперсия – наименьшая, по сравнению с другими несмещенными оценками.*

На практике оценка не всегда удовлетворяет всем этим требованиям одновременно.

Пример 4.7. *Доказать, что выборочное среднее $\bar{x}$ является несмещенной и состоятельной оценкой для математического ожидания (генерального среднего) случайной величины.*

◀Обозначим $M(\xi) = a,\ D(\xi) = \sigma^2$. Рассматривая $\bar{x}$ как случайную величину, найдем ее математическое ожидание. При этом, как было отмечено ранее, считаем

$M(\xi_1) = \ldots = M(\xi_n) = a, \quad D(\xi_1) = \ldots = D(\xi_n) = \sigma^2.$

$$M(\xi) = M\left(\frac{\sum\limits_{i=1}^{n}\xi_i}{n}\right) = \frac{\sum\limits_{i=1}^{n} M(\xi_i)}{n} = \frac{na}{n} = a.$$

Несмещенность выборочного среднего доказана. Оценим теперь дисперсию выборочного среднего:

$$D(\xi) = D\left(\frac{\sum_{i=1}^{n}\xi_i}{n}\right) = \frac{\sum_{i=1}^{n} D(\xi_i)}{n^2} = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

В соответствии с неравенством Чебышева (теорема 2.3), получаем $\forall\, \varepsilon > 0$:

$$1 \geqslant P\big(\big|\xi - M(\xi)\big| < \varepsilon\big) \geqslant 1 - \frac{\sigma^2/n}{\varepsilon^2}.$$

Заменяя $M(\xi) = a$ и переходя к пределу при $n \to \infty$, получаем

$$1 \geqslant \lim_{n\to\infty} P\big(\big|\xi - a\big| < \varepsilon\big) \geqslant 1,$$

откуда получаем:

$$\lim_{n\to\infty} P\big(\big|\xi - a\big| < \varepsilon\big) = 1.$$

Это равенство и означает состоятельность оценки $\bar{x}$.

Замечание 4.2. *Можно доказать, что выборочное среднее будет эффективной оценкой математического ожидания в случае, когда случайная величина имеет нормальное распределение.*

Аналогично доказывается, что выборочная дисперсия S^2 является состоятельной и смещенной оценкой дисперсии σ^2:

$$M(S^2) = \frac{n-1}{n}\,\sigma^2. \tag{4.10}$$

Примем это без доказательства.

При малых объемах выборки n для оценки дисперсии σ^2 используют исправленную выборочную дисперсию S^{*^2}:

$$S^{*^2} = \frac{n}{n-1}\,S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2. \tag{4.11}$$

Оценка S^{*^2} является несмещенной, состоятельной оценкой дисперсии σ^2.

Формула (4.11) позволяет вычислять S^{*^2} для простой совокупности. Для сгруппированных данных используют аналогичную формулу (4.12):

$$S^{*^2} = \frac{1}{n-1}\sum_{i=1}^{k} m_i(x_i - \bar{x})^2. \tag{4.12}$$

Замечание 4.3. *Исправленное СКО S^* является смещенной оценкой СКО S.*

4.6. Распределения, используемые в статистике

Познакомимся с некоторыми непрерывными распределениями, которые применяются в математической статистике.

Распределение χ^2 (хи-квадрат).

Пусть имеется n независимых стандартных нормальных случайных величин $\xi_1, \xi_2, \ldots, \xi_n$, $\xi_i \sim N(0;1)$, $i = 1, \ldots, n$.

Определение 4.10. *Распределение случайной величины $\chi^2_n = \sum_{i=1}^{n} \xi_i^2$ называется χ^2—**распределением** с n степенями свободы.*

Очевидно, что случайная величина $\chi^2_n \geqslant 0$.

Плотность этого распределения имеет вид:

$$f(x) = \begin{cases} \dfrac{x^{\frac{k}{2}-1}}{\Gamma\left(\frac{k}{2}\right)2^{\frac{k}{2}}} e^{-\frac{x}{2}} & \text{при} \quad x \geqslant 0, \\ 0 & \text{при} \quad x < 0. \end{cases}$$

Здесь $\Gamma(x) = \int\limits_0^\infty t^{x-1} \cdot e^{-t} dt$ — гамма функция, являющаяся обобщением понятия факториала: $\Gamma(x) = (x-1)!$ при $x \geqslant 1$.

Замечание 4.4. *Если случайные величины $\xi_1, \ldots, \xi_n$ связаны какой-нибудь зависимостью, например $\xi_1 + \ldots + \xi_n = n \cdot \overline{x}$, то число степеней свободы уменьшается, случайная величина $\sum_{i=1}^{n} \xi_i^2$ будет иметь распределение χ^2_{n-1}.*

Распределение Стьюдента.

Пусть имеется $n+1$ независимая нормальная стандартная случайная величина $\zeta, \xi_1, \ldots, \xi_n$.

Определение 4.11. *Распределение случайной величины*

$$t = \frac{\zeta}{\sqrt{\frac{\chi_n^2}{n}}}$$

называется ***распределением Стьюдента*** *с n степенями свободы.*

Плотность этого распределения имеет вид:

$$f_{st}(x) = \frac{\left(1 + \frac{x^2}{2}\right)^{\frac{n+1}{2}}}{2^{\frac{n-1}{2}}\Gamma\left(\frac{n}{2}\right)\sqrt{\pi n}}.$$

Поскольку распределение симметрично относительно нуля (плотность — четная функция), математическое ожидание равно нулю.

Стьюдент — псевдоним английского статистика Госсета.

F—Распределение Фишера—Снедекора.

Пусть имеется $n+k$ независимых нормальных стандартных величин: $\xi_1, \ldots, \xi_n$; $\zeta_1, \ldots, \zeta_k$; $\xi_i \sim N(0;1),\ i = 1,\ \ldots, n$; $\zeta_i \sim N(0;1),\ j = 1, \ldots, k$.

Определение 4.12. *Распределение случайной величины*

$$F_{n,k} = \frac{\frac{\chi_n^2}{n}}{\frac{\chi_k^2}{k}}$$

называется ***F—распределением Фишера—Снедекора*** *(распределением Фишера или F—распределением) с $n,\ k$ степенями свободы.*

Очевидно, что случайная величина $F_{n,k} \geqslant 0$.

Плотность этого распределения имеет вид:

$$f(x) = \begin{cases} \dfrac{\Gamma\left(\dfrac{m+k}{2}\right)}{\Gamma\left(\dfrac{n}{2}\right) \cdot \Gamma\left(\dfrac{k}{2}\right)} \left(\dfrac{n}{k}\right)^{\frac{n}{2}} \cdot x^{\frac{n}{2}-1} \left(1 + \dfrac{n}{k}x\right)^{-\frac{n+k}{2}} & \text{при} \quad x \geqslant 0, \\ 0 & \text{при} \quad x < 0. \end{cases}$$

Для всех этих распределений имеются таблицы значений плотности и функции распределения; их можно также вычислить с помощью прикладных программ на ЭВМ (таких, как Excel, Mathcad, Maxima и проч.).

4.7. Интервальные оценки параметров распределения

Наряду с рассмотренными точечными оценками, определяемыми одним числом, используют интервальные оценки неизвестных параметров, определяемые двумя числами — концами интервала, дающими вероятностную оценку сверху и снизу неизвестного параметра распределения.

Интервальные оценки целесообразно применять при малом объеме выборки, когда дисперсия точечной оценки велика и она может сильно отличаться от оцениваемого параметра.

Определение 4.13. ***Доверительным интервалом*** *для несмещенного параметра a называют интервал $(a_1; a_2)$ со случайными границами, зависящими от наблюдений: $a_1 = a_1(x_1, \ldots, x_n)$, $a_2 = a_2(x_1, \ldots, x_n)$, накрывающий неизвестный параметр с заданной вероятностью γ: $P(a \in (a_1; a_2)) = \gamma$.* ***Вероятность*** *$\gamma$ называется* ***доверительной вероятностью*** *или* ***надежностью доверительного интервала****.*

Обычно γ задают равным $0{,}95; 0{,}99$ и более.

Доверительный интервал $\mathbf{I}_\gamma$ для неизвестного математического ожидания нормального распределения при известной дисперсии имеет вид:

$$\mathbf{I}_\gamma = \left(\bar{x} - \tau_{\gamma/2}\frac{\sigma}{\sqrt{n}};\ \bar{x} + \tau_{\gamma/2}\frac{\sigma}{\sqrt{n}}\right), \tag{4.13}$$

где величина $\tau_{\gamma/2}$ определяется из уравнения:

$$\Phi(\tau_{\gamma/2}) = \frac{\gamma}{2} \tag{4.14}$$

по таблицам функции Лапласа или с помощью компьютера, а $\bar{x}$ — выборочное среднее.

Замечание 4.5. *При возрастании объема выборки n, как видно из (4.13), доверительный интервал уменьшается. При увеличении надежности γ увеличивается величина $\tau_{\gamma/}$, т.к. функция Лапласа в (4.14) возрастающая; следовательно, увеличивается и доверительный интервал (4.13).*

Для получения доверительного интервала (4.13) заметим, что если независимые случайные величины $\xi_i \sim N(a; \sigma)$, $i = 1, \ldots, n$, то среднее арифметическое $\bar{\xi} = (\xi_1 + \ldots \xi_n)/n$ тоже распределено нормально с параметрами:

$$M(\bar{\xi}) = a, \quad \sigma(\bar{\xi}) = \frac{\sigma}{\sqrt{n}}. \tag{4.15}$$

Формулы (4.15) были получены в примере 4.7. Будем искать доверительный интервал для a в виде:

$$P(|\bar{\xi} - a| < \varepsilon) = \gamma, \tag{4.16}$$

где γ — заданная доверительная вероятность. Для определения ε воспользуемся формулой (2.47), которая в данном случае с учетом (4.15) принимает вид:

$$P(|\bar{\xi} - a| < \varepsilon) = 2\Phi\Big(\frac{\varepsilon}{\sigma/\sqrt{n}}\Big).$$

Найдем ε из уравнения:

$$2\Phi\Big(\frac{\varepsilon}{\sigma/\sqrt{n}}\Big) = \gamma \implies \Phi\Big(\frac{\varepsilon}{\sigma/\sqrt{n}}\Big) = \frac{\gamma}{2} \implies \frac{\varepsilon}{\sigma/\sqrt{n}} = \tau_{\frac{\gamma}{2}} \implies$$
$$\varepsilon = \tau_{\frac{\gamma}{2}} \cdot \frac{\sigma}{\sqrt{n}}.$$

С учетом полученной величины ε доверительный интервал (4.16) принимает вид (4.13).

Пример 4.8. *Найти доверительный интервал* $\mathbf{I}_\gamma$ *для неизвестного математического ожидания* a *нормально распределенной случайной величины со средним квадратическим отклонением* $\sigma = 2$ *по выборке объема* $n = 64$ *с выборочным средним* $\bar{x} = 5{,}2$. *Надежность доверительного интервала* $\gamma = 0{,}95$.

◀ Из уравнения (4.14) по таблице приложения 2 находим для $\frac{\gamma}{2} = 0{,}475$ $\tau_{\frac{\gamma}{2}} = 1{,}96$. Подставляя найденное значение в (4.13), получаем $\mathbf{I}_\gamma = (4{,}71; 5{,}69)$.

Ответ: $\mathbf{I}_\gamma = (4{,}71; 5{,}69)$.

Доверительный интервал $\mathbf{I}_\gamma$ *для неизвестного математического ожидания нормального распределения при неизвестной дисперсии имеет вид:*

$$\mathbf{I}_\gamma = \Big(\bar{x} - t_\gamma \frac{S^*}{\sqrt{n}};\ \bar{x} + t_\gamma \frac{S^*}{\sqrt{n}}\Big), \tag{4.17}$$

где величина t_γ определяется по таблице приложения 3 критических точек распределения Стьюдента для $\alpha = 1 - \gamma$ и $k = n - 1$ или с помощью компьютера из уравнения для функции распределения Стьюдента $F_{st}(x)$ с $n - 1$ степенью свободы:

$$F_{st}(t_\gamma) = \frac{1 + \gamma}{2}, \tag{4.18}$$

где $\bar{x}$ и S^* — соответственно выборочное среднее и исправленное СКО.

Для получения доверительного интервала (4.17) примем без доказательства, что если независимые случайные величины $\xi_i \sim N(a;\sigma)$, $i = 1, \ldots, n$, то случайная величина

$$t = \frac{\bar{\xi} - a}{S^*/\sqrt{n}} \tag{4.19}$$

имеет распределение Стьюдента с $n-1$ степенью свободы (см п. 4.6).

Обозначим t_γ значение, при котором с вероятностью γ выполняется следующее неравенство:

$$P(|t| < t_\gamma) = \gamma. \tag{4.20}$$

С учетом четности плотности распределения Стьюдента $f_{st}(t)$ значение t_γ определяется из условия:

$$P(|t| < t_\gamma) = \gamma \iff P(|t| > t_\gamma) = 1-\gamma \implies P(t > t_\gamma) = \frac{1-\gamma}{2} \iff$$
$$\iff 1 - F_{st}(t_\gamma) = \frac{1-\gamma}{2} \iff F_{st}(t_\gamma) = \frac{1+\gamma}{2}.$$

Подставляя в (4.20) выражение (4.19), получаем:

$$P\left\{\left|\frac{\bar{\xi} - a}{S^*/\sqrt{n}}\right| < t_\gamma\right\} = \gamma \iff P\left\{-t_\gamma < \frac{\bar{\xi} - a}{S^*/\sqrt{n}} < t_\gamma\right\} = \gamma,$$

откуда получаем для a доверительный интервал в виде (4.17).

Замечание 4.6. *В некоторых пакетах прикладных программ для ЭВМ, например в Excel, под распределением Стьюдента понимается* $1 - F_{st}(x)$. *Поэтому, задавая значение* $1-\gamma$ *и число свободы, с помощью обратной функции можно сразу получить значение* t_γ *для двустороннего интервала (без использования (4.18)). Указанные особенности можно узнать из инструкций к программам.*

Пример 4.9. *Найти доверительный интервал* $\mathbf{I}_\gamma$ *для неизвестного математического ожидания* a *нормально распределенной случайной величины с выборочным средним* $\bar{x} = 10{,}5$ *и исправленным СКО* $S^* = 1{,}6$ *по выборке объема* $n = 16$. *Надежность доверительного интервала* $\gamma = 0{,}99$.

◀ По таблице приложения 3 для числа степеней свободы $k = n - 1 = 15$ и $\alpha = 1 - \gamma = 0{,}01$ находим $t_\gamma = 2{,}95$. Подставляя полученное значение в (4.17), получаем значение для радиуса доверительного интервала

ε:

$$\varepsilon = t_\gamma \frac{S^*}{\sqrt{n}} = 2{,}95 \frac{1{,}6}{\sqrt{16}} = 2{,}95 \cdot 0{,}4 = 1{,}18.$$

Находим доверительный интервал

$\mathbf{I}_\gamma = (10{,}5 - 1{,}18; 10{,}5 + 1{,}18) = (9{,}32; 11{,}68)$.

Ответ: $\mathbf{I}_\gamma = (9{,}32; 11{,}68)$.

4.8. Выборочный коэффициент корреляции

Рассмотрим выборку объема n из генеральной совокупности значений двумерной случайной величины $(\xi; \eta)$, т.е. n пар наблюдений $(x_i; y_i)$. Поскольку многие значения в этой выборке могут повторяться, их заносят в так называемую корреляционную таблицу (табл. 4.4).

Таблица 4.4

Корреляционная таблица					
$\xi \backslash \eta$	y_1	y_2	$\dots$	y_s	n_{i*}
x_1	n_{11}	n_{12}	$\dots$	n_{1s}	n_{1*}
x_2	n_{21}	n_{22}	$\dots$	n_{2s}	n_{2*}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
x_k	n_{k1}	n_{k2}	$\dots$	n_{ks}	n_{k*}
n_{*j}	n_{*1}	n_{*2}	$\dots$	n_{*s}	n

В первом столбце этой таблицы перечислены значения x_i, во второй строке — y_i. Данные представлены в виде вариационных рядов. На пересечении i-й строки и j-го столбца — соответствующая частота n_{ij}, т.е. количество раз, которое наблюдение $(x_i; y_j)$ встретилось в выборке. При обработке корреляционной таблицы в последнем столбце указывают сумму частот по строкам $n_{i*} = \sum_{j=1}^{s} n_{ij}$, а в последней строке — сумму частот по столбцам $n_{*j} = \sum_{i=1}^{k} n_{ij}$. Сумма всех элементов последнего столбца или строки даст объем выборки

$$n = \sum_{i=1}^{k} \sum_{j=1}^{s} n_{ij} = \sum_{i=1}^{k} n_{i*} = \sum_{j=1}^{s} n_{*j}.$$

Первый и последний столбцы корреляционной таблицы образуют статистическое распределение выборки случайной величины ξ, а первая и последняя строки образуют выборку случайной величины η. Обработав их, как описано в предыдущей лекции, получим числовые характеристики

$$\overline{x} = \frac{\sum\limits_{i=1}^{k} n_{i*} x_i}{n}, \quad \overline{x^2} = \frac{\sum\limits_{i=1}^{k} n_{i*} x_i^2}{n}, \quad S_x^2 = \overline{x^2} - \overline{x}^2,$$

$$\overline{y} = \frac{\sum\limits_{j=1}^{s} n_{*j} y_j}{n}, \quad \overline{y^2} = \frac{\sum\limits_{j=1}^{s} n_{*j} y_j^2}{n}, \quad S_y^2 = \overline{y^2} - \overline{y}^2.$$

Определение 4.14. ***Выборочным коэффициентом корреляции*** r^*_{xy} *называется:*

$$r^*_{xy} = \frac{\overline{xy} - \overline{x} \cdot \overline{y}}{S_x \cdot S_y}, \quad \textit{где} \tag{4.21}$$

$$\overline{xy} = \frac{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{s} n_{ij} x_i y_j}{n}. \tag{4.22}$$

Выборочный коэффициент корреляции является статистической оценкой коэффициента корреляции, рассмотренного в п.6.5, и он обладает следующими свойствами, которые мы приведем без доказательства:

1) $r^*_{xy} = r^*_{yx}$;

2) Выборочный коэффициент корреляции находится в пределах от -1 до 1: $-1 \leqslant r^*_{xy} \leqslant 1$;

3) $|r^*_{xy}| = 1$ тогда и только тогда, когда между значениями x_i и y_i имеется линейная зависимость. Чем ближе r^*_{xy} к нулю, тем хуже эта зависимость аппроксимируется линейной.

Определение 4.15. *Условным средним* $\overline{y_x}$ *называют среднее арифметическое значений* η *при фиксированном значении* $\xi = x$.

Для корреляционной таблицы 4.4 условное среднее $\overline{y_x}$ *получается усреднением значений* η *по строке, соответствующей* $\xi = x$. *Так, например,* $\overline{y_{x_1}} = \dfrac{\sum\limits_{j=1}^{S} y_j n_{1j}}{n_1 * .}$. *Аналогично определяется условное среднее* $\overline{x_y}$.

4.9. Проверка статистических гипотез

Определение 4.16. ***Статистической*** *называется гипотеза о виде распределения или о значениях его параметров.*

Гипотезы будем обозначать $H_0,\ H_1,\ H_2,\ \ldots$.

Различают проверяемую или основную гипотезу H_0 и альтернативную или конкурирующую H_1, которая должна противоречить основной.

Пример 4.10. *Проверяемая гипотеза H_0 состоит в том, что математическое ожидание случайной величины ξ равно заданному значению a_0. $H_0:\ M(\xi) = a_0$. Альтернативная $H_1:\ M(\xi) > a_0$.*

Для проверки статистической гипотезы на основании выборки $x_1,\ x_2,\ \ldots,\ x_n$ вычисляют значение критерия, зависящего от наблюдений:

$$T = T(x_1,\ x_2,\ \ldots\ x_n).$$

Все множество значений критерия делится на так называемую критическую область, при попадании в которую значения критерия проверяемая гипотеза отвергается, и область принятия гипотезы.

При принятии решения о справедливости гипотезы H_0 возможны следующие ошибки:

— гипотеза H_0 отвергается, хотя на самом деле она верна (ошибка первого рода) ;

— гипотеза H_0 принимается, хотя на самом деле она не верна, а справедлива гипотеза H_1 (ошибка второго рода) .

Наряду с этим возможны следующие правильные решения:

— гипотеза H_0 принимается и она действительно верна;

— гипотеза H_0 отвергается и на самом деле справедлива гипотеза H_1.

Определение 4.17. *Вероятность ошибки первого рода называется уровнем значимости критерия и обычно обозначается α.*

Вероятность правильно отвергнуть проверяемую гипотезу называется мощностью критерия и обычно обозначается β, тогда вероятность ошибки второго рода равна $1 - \beta$.

Одновременно уменьшить вероятности ошибок первого и второго рода можно только увеличив объем выборки n.

При фиксированном n обычно задают допустимый уровень ошибки первого рода α и стараются минимизировать вероятность ошибки второго рода $1-\beta$, т.е. максимизировать мощность критерия β.

На практике при проверке статистической гипотезы на основании наблюдений вычисляют наблюдаемое значение критерия $T_{\text{набл}}$ и по заданному уровню значимости α определяют границы критической области — критические точки.

Критические области бывают двусторонние и односторонние: левосторонняя и правосторонняя.

Если критическая область правосторонняя, т.е. $(t_{\text{кр2}};\ +\infty)$, при выполнении условия $T_{\text{набл}} > t_{\text{кр2}}$ делают вывод: проверяемая гипотеза H_0 отвергается с уровнем значимости α в пользу гипотезы H_1; если это условие не выполняется, т.е. $T_{\text{набл}} \leqslant t_{\text{кр2}}$, делают более осторожный вывод: нет оснований для того, чтобы отвергнуть гипотезу H_0 в пользу гипотезы H_1 с уровнем значимости α.

Если критическая область левосторонняя, т.е. $(-\infty;\ t_{\text{кр1}})$, гипотеза H_0 отвергается при выполнении условия $T_{\text{набл}} < t_{\text{кр1}}$.

В случае двусторонней критической области вида $(-\infty;\ t_{\text{кр1}}) \cup (t_{\text{кр2}};\ +\infty)$ гипотеза H_0 отвергается при выполнении условия $T_{\text{набл}} < t_{\text{кр1}}$ или $T_{\text{набл}} > t_{\text{кр2}}$.

4.10. Проверка гипотезы о значимости выборочного коэффициента корреляции

Пусть на основании данных корреляционной таблицы по выборке объема n независимых наблюдений над нормально распределенными случайными величинами найден выборочный коэффициент корреляции r^*_{xy}, который оказался отличным от нуля.

Так как выборка отобрана случайно, возникает вопрос о том, будет ли отличен от нуля теоретический коэффициент корреляции $r_{\xi\zeta}$, к которому сходится выборочный коэффициент при $n \to \infty$.

Необходимо при заданном уровне значимости α проверить гипотезу H_0 : $r_{\xi\zeta} = 0$ при альтернативной гипотезе H_1 : $r_{\xi\zeta} \neq 0$.

Если H_0 отвергается, это означает, что выборочный коэффициент корреляции значимо отличается от нуля, а случайные величины ξ и ζ коррелированы, т.е. в той или иной степени связаны линейной зависимостью.

Если H_0 принимается, это означает, что выборочный коэффициент корреляции незначимо отличается от нуля, а случайные величины ξ и ζ некоррелированы, т.е. не связаны линейной зависимостью.

В качестве критерия для проверки H_0 выбирается случайная величина

$$T = r^*_{xy} \frac{\sqrt{n-2}}{\sqrt{1 - {r^*_{xy}}^2}}, \tag{4.23}$$

где r^*_{xy} вычисляется по формуле (4.21). При справедливости гипотезы H_0 величина T имеет так называемое распределение Стьюдента с $n-2$ степенями свободы.

Критическая область для рассматриваемой гипотезы H_0 будет двусторонней, $t_{\text{кр1}} = -t_{\text{кр2}}$.

Критическая точка $t_{\text{кр2}}$ определяется по заданным уровню значимости α и числу степеней $n-2$ по специальным таблицам (приложение 3) или с помощью обратной к функции распределения Стьюдента, имеющейся, например, среди статистических функций Excel для $\alpha/2$ и $n-2$ степеней свободы.

По формуле (4.23) для данных наблюдений определяем значение критерия $T_{\text{набл}}$.

Если $|T_{\text{набл}}| > t_{\text{кр2}}$, гипотеза H_0 отвергается с уровнем значимости α, если $|T_{\text{набл}}| \leqslant t_{\text{кр2}}$ — нет оснований отвергнуть H_0.

4.11. Сравнение двух математических ожиданий

Пусть имеются две независимые выборки объемов n и m из нормальных совокупностей с известными дисперсиями σ_1^2 и σ_2^2. Требуется по найденным выборочным средним $\bar{x}$ и $\bar{y}$ с уровнем значимости α проверить нулевую гипотезу H_0 о равенстве теоретических математических ожиданий:

$$H_0: \quad M(\xi) = M(\zeta).$$

Заметим, что в силу несмещенности оценок $\bar{x}$ и $\bar{y}$ следует, что нулевую гипотезу можно записать и так:

$$H_0: \quad M(\bar{\xi}) = M(\bar{\zeta}).$$

Другими словами, требуется проверить значимо или нет отличаются между собой выборочные средние. В качестве критерия проверки гипотезы примем величину:

$$Z = \frac{\bar{x} - \bar{y}}{\sqrt{\dfrac{\sigma_1^2}{n} + \dfrac{\sigma_2^2}{m}}}. \tag{4.24}$$

Для изучения ее свойств рассмотрим соответствующую случайную величину:

$$Z = \frac{\bar{\xi} - \bar{\zeta}}{\sqrt{\dfrac{\sigma_1^2}{n} + \dfrac{\sigma_2^2}{m}}}, \quad \text{где} \quad \bar{\xi} = \frac{\sum\limits_{i=1}^{n} \xi_i}{n},\ \bar{\zeta} = \frac{\sum\limits_{i=1}^{m} \zeta_i}{m}\ .$$

Если верна гипотеза H_0, т.е. $\xi_i \sim N(a;\sigma_1)$, $\zeta_i \sim N(a;\sigma_2)$,
то $Z \sim N(0;1)$.

Действительно, Z является линейной комбинацией нормально распределенных случайных величин, и поэтому сама распределена нормально. Ее математическое ожидание и дисперсия равны:

$$M(Z) = \big(M(\bar{\xi}) - M(\bar{\zeta})\big) \Big/ \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} =$$

$$= \left(\sum_{i=1}^{n} M(\xi_i)/n - \sum_{i=1}^{m} M(\zeta_i)/m\right) \Big/ \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} =$$

$$= \left(\frac{na}{n} - \frac{ma}{m}\right) \Big/ \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} = 0,$$

$$D(Z) = \big(D(\bar{\xi}) + D(\bar{\zeta})\big) \Big/ \left(\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right) =$$

$$= \left(\sum_{i=1}^{n} D(\xi_i)/n^2 + \sum_{i=1}^{m} D(\zeta_i)/m^2\right) \Big/ \left(\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right) =$$

$$= \left(\frac{n\sigma_1^2}{n^2} + \frac{m\sigma_2^2}{m^2}\right) \Big/ \left(\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right) = 1.$$

Поэтому, в зависимости от конкурирующей гипотезы, решающее правило выглядит следующим образом:

- $H_0: \quad M(\xi) = M(\zeta), \qquad H_1: \quad M(\xi) \neq M(\zeta).$

Критическая область двусторонняя с вероятностью $\alpha/2$ попадания в каждую половину в случае справедливости H_0.

Из уравнения $F_{\text{ст}}(Z_{\text{кр}}) = 1-\alpha/2$, где $F_{\text{ст}}(Z)$ — функция распределения стандартного нормального закона, находим значение $Z_{\text{кр}}$, вычисляем по данным наблюдениям значение критерия $Z_{\text{набл}}$ и если $|Z_{\text{набл}}| > Z_{\text{кр}}$, то отвергаем гипотезу H_0 с уровнем значимости α.

Если $|Z_{\text{набл}}| \leqslant Z_{\text{кр}}$, у нас нет оснований отвергнуть гипотезу H_0 в пользу данной гипотезы H_1.

На практике уравнение $F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha/2$ решают или с помощью ЭВМ (например, Excel), или по таблице приложения 2 и уравнения (4.25) т.к.

$$F_{\text{ст}}(Z_{\text{кр}}) = \Phi(Z_{\text{кр}}) + 0{,}5 \implies F_{\text{ст}}(Z_{\text{кр}}) = 1 - \frac{\alpha}{2} \iff$$
$$\iff \Phi(Z_{\text{кр}}) + 0{,}5 = 1 - \frac{\alpha}{2} \iff$$

$$\Phi(Z_{\text{кр}}) = \frac{1}{2} - \frac{\alpha}{2}. \tag{4.25}$$

- $$H_0: \quad M(\xi) = M(\zeta), \qquad H_2: \quad M(\xi) > M(\zeta).$$

Критическая область правосторонняя с вероятностью α попадания в нее в случае справедливости H_0.

Из уравнения $F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha$ находим значение $Z_{\text{кр}}$, вычисляем по формуле (4.24) $Z_{\text{набл}}$ и если $Z_{\text{набл}} > Z_{\text{кр}}$, то отвергаем гипотезу H_0 с уровнем значимости α.

Если $Z_{\text{набл}} \leqslant Z_{\text{кр}}$, то нет оснований отвергнуть гипотезу H_0.

На практике $Z_{\text{кр}}$ находят или с помощью ЭВМ, или по таблице приложения 2, из уравнения (4.26) т.к.

$$F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha \iff \Phi(Z_{\text{кр}}) + 0{,}5 = 1 - \alpha \iff$$

$$\Phi(Z_{\text{кр}}) = \frac{1}{2} - \alpha; \tag{4.26}$$

- $$H_0: \quad M(\xi) = M(\zeta), \qquad H_3: \quad M(\xi) < M(\zeta).$$

Критическая область – левосторонняя с вероятностью α попадания в нее в случае справедливости H_0.

Из уравнения $F_{\text{ст}}(Z'_{\text{кр}}) = \alpha$ находим значение $Z'_{\text{кр}}$.

В силу симметрии нормального распределения относительно нуля на практике находят значение $Z_{\text{кр}}$ из уравнения (4.26) и берут $Z'_{\text{кр}} = -Z_{\text{кр}}$.

Если $Z_{\text{набл}} < -Z_{\text{кр}}$, гипотезу H_0 отвергают с уровнем значимости α, если $Z_{\text{набл}} \geqslant -Z_{\text{кр}}$, то нет оснований отвергнуть H_0.

Замечание 4.7. *Если независимые выборки достаточно большие, указанный критерий можно применять для случая неизвестных дисперсий и не обязательно нормального распределения совокупностей.*

В этом случае вместо формулы (4.24) используют формулу (4.27) для вычисления критерия Крамера-Уэлча:

$$Z = \frac{\bar{x} - \bar{y}}{\sqrt{\dfrac{S_1^{*2}}{n} + \dfrac{S_2^{*2}}{m}}}. \tag{4.27}$$

4.12. Сравнение математического ожидания с заданным значением

Пусть имеется выборка объема n нормальной совокупности с известной дисперсией σ^2. Требуется по найденной выборочной средней с уровнем значимости α проверить гипотезу H_0 о равенстве неизвестного математического ожидания $M(\xi)$ заданному значению a_0:

$$H_0: \quad M(\xi) = a_0.$$

В силу несмещенности оценки $\bar{x}$ заключаем, что нулевую гипотезу можно записать и так:

$$H_0: \quad M(\bar{\xi}) = a_0.$$

Другими словами, требуется проверить, значимо или нет отличается выборочное среднее от заданного значения. В качестве критерия выберем величину

$$U = \frac{\bar{x} - a_0}{\sigma/\sqrt{n}} = \frac{\bar{x} - a_0}{\sigma} \cdot \sqrt{n}. \tag{4.28}$$

Можно доказать (сделайте это самостоятельно), что соответствующая случайная величина $U = \dfrac{(\bar{\xi} - a_0)}{\sqrt{n}/\sigma}$ имеет стандартное нормальное распределение. Поэтому, в зависимости от конкурирующей гипотезы, решающее правило будет следующим:

- $H_0: \quad M(\xi) = a_0; \qquad H_1: \quad M(\xi) \neq a_0.$

Из уравнения (4.25) по таблице приложения 2 (или с помощью ЭВМ) определяем $Z_{\text{кр}}$, по формуле (4.28) находим $U_{\text{набл}}$ для имеющихся наблюдений.

Если $|U_{\text{набл}}| > Z_{\text{кр}}$, гипотезу H_0 отвергаем с уровнем значимости α, если $|U_{\text{набл}}| \leqslant Z_{\text{кр}}$, то нет оснований отвергнуть гипотезу H_0 в пользу данной гипотезы H_1.

- $$H_0: \quad M(\xi) = a_0; \qquad H_2: \quad M(\xi) > a_0.$$

Из уравнения (4.26) определяем $Z_{\text{кр}}$, по формуле (4.28) находим $U_{\text{набл}}$. Если $U_{\text{набл}} > Z_{\text{кр}}$, гипотезу H_0 отвергаем с уровнем значимости α, если $U_{\text{набл}} \leqslant Z_{\text{кр}}$, то нет оснований отвергнуть H_0.

- $$H_0: \quad M(\xi) = a_0; \qquad H_3: \quad M(\xi) < a_0.$$

Из уравнения (4.26) определяем $Z_{\text{кр}}$, по формуле (4.28) находим $U_{\text{набл}}$. Если $U_{\text{набл}} < -Z_{\text{кр}}$, гипотезу H_0 отвергаем с уровнем значимости α, если $U_{\text{набл}} \geqslant -Z_{\text{кр}}$, то нет оснований отвергнуть H_0.

Если в условиях п. 8.4 дисперсия неизвестна, в качестве критерия следует выбрать величину

$$T = \frac{\bar{x} - a_0}{S^*/\sqrt{n}} = \frac{\bar{x} - a_0}{S^*} \cdot \sqrt{n}. \tag{4.29}$$

Можно доказать (мы не будем этого делать), что соответствующая случайная величина $T = (\bar{\xi} - a_0) \cdot \sqrt{n}/S^*$ имеет распределение Стьюдента с $n-1$ степенью свободы. Решающее правило в зависимости от конкурирующей гипотезы будет следующим:

- $$H_0: \quad M(\xi) = a_0; \qquad H_1: \quad M(\xi) \neq a_0.$$

Критическая область в данном случае будет двусторонней; критическая точка t_2 определяется по заданным α и $n-1$ по специальным таблицам (приложение 3) или с помощью функции, обратной к функции распределения Стьюдента, имеющейся, например, среди статистических функций Excel. По формуле (4.29) определяем $T_{\text{набл}}$.

Если $|T_{\text{набл}}| > t_2$, гипотеза H_0 отвергается с уровнем значимости α, если $|T_{\text{набл}}| \leqslant t_2$, то нет оснований отвергнуть H_0 в пользу данной гипотезы H_1.

При конкурирующих гипотезах $H_2: \ M(\xi) > a_0$ и $H_3: \ M(\xi) < a_0$ строят соответственно правостороннюю и левостороннюю критические области (см. [5]).

4.13. Сравнение двух дисперсий (критерий Фишера)

Пусть по независимым выборкам объемов n_1 и n_2 из нормальных совокупностей найдены исправленные выборочные дисперсии $S_1^{*^2}$ и $S_2^{*^2}$, где $S_1^{*^2}$ – большая из них. Требуется при заданном уровне значимости α проверить нулевую гипотезу H_0 о равенстве теоретических дисперсий:

$$H_0: \ \sigma_1^2 = \sigma_2^2.$$

Заметим, что в силу несмещенности оценок $S_1^{*^2}$ и $S_2^{*^2}$ нулевую гипотезу можно записать и так:

$$H_0: \ M(S_1^{*^2}) = M(S_2^{*^2}).$$

В качестве критерия проверки гипотезы примем отношение большей исправленной дисперсии к меньшей:

$$F = \frac{S_1^{*^2}}{S_2^{*^2}}.$$

Известно, что при условии справедливости нулевой гипотезы, величина F имеет распределение Фишера–Снедекора (см. п. 4.6) со степенями свободы $k_1 = n_1 - 1, \ k_2 = n_2 - 1$. Решающее правило зависит от конкурирующей гипотезы.

- $H_0: \ \sigma_1^2 = \sigma_2^2, \quad H_1: \ \sigma_1^2 > \sigma_2^2.$
  В этом случае строят правостороннюю критическую область, исходя из того, что при справедливости H_0 ($\sigma_1^2 = \sigma_2^2$) вероятность больших значений F мала: $P\{F > t_2(\alpha; k_1; k_2)\} = \alpha$. Критическую точку $t_2(\alpha; k_1; k_2)$ находят по таблице критических точек распределения Фишера–Снедекора (приложение 5) или, например, с помощью обратной функции F–распределения среди статистических функций Excel. Если $F_{\text{набл}} > t_2(\alpha; k_1; k_2)$, гипотезу H_0 отвергают с уровнем значимости α.

- $H_0: \ \sigma_1^2 = \sigma_2^2, \quad H_2: \ \sigma_1^2 \neq \sigma_2^2.$
  В этом случае строят двустороннюю критическую область так, чтобы вероятности попадания в левую и правую половину были бы равны

$\alpha/2$:

$$P\{F < t_1(\alpha/2; k_1; k_2)\} = P\{F > t_2(\alpha/2; k_1; k_2)\} = \frac{\alpha}{2}.$$

Критическую точку $t_2(\alpha/2; k_1; k_2)$ находят по таблице приложения 5 или с помощью ЭВМ. Если $F_{\text{набл}} > t_2(\alpha/2; k_1; k_2)$, гипотезу H_0 отвергают с уровнем значимости α.

- $H_0: \ \sigma_1^2 = \sigma_2^2, \quad H_3: \ \sigma_1^2 < \sigma_2^2$.
  Поскольку $S_1^{*^2} > S_2^{*^2}$, без дополнительного исследования ясно, что при конкурирующей гипотезе H_3 гипотеза H_0 предпочтительнее. Этот случай очевиден.

Пример 4.11. *По двум независимым выборкам из нормальных генеральных совокупностей, объемы которых равны* $n_1 = 12$ *и* $n_2 = 15$, *найдены исправленные выборочные дисперсии* $S_1^{*^2} = 10$, $S_2^{*^2} = 5{,}5$. *С уровнем значимости* $\alpha = 0{,}05$ *проверить нулевую гипотезу о равенстве дисперсий* $H_0: \ \sigma_1^2 = \sigma_2^2$ *при конкурирующей гипотезе* $H_1: \ \sigma_1^2 > \sigma_2^2$.

Р е ш е н и е: В данном примере $k_1 = 12 - 1 = 11, \ k_2 = 15 - 1 = 14$, $F_{\text{набл}} = \dfrac{S_1^{*^2}}{S_2^{*^2}} = 1{,}82$. Выбираем среди статистических функций Excel обратное F–распределение и находим $t_2(0{,}05; 11; 14) = 2{,}56$. Так как $F_{\text{набл}} < t_2(\alpha; k_1; k_2)$, то нет оснований отвергнуть нулевую гипотезу о равенстве дисперсий.

4.14. Сравнение вероятности с заданным значением

Пусть проведено n независимых испытаний Бернулли с неизвестной вероятностью p появления события A в каждом. По результатам испытаний найдена относительная частота m/n, где m — число появлений события A в n испытаниях. Требуется по величине m/n с уровнем значимости α проверить нулевую гипотезу H_0 о том, что неизвестная вероятность p равна заданному значению p_0:

$$H_0: \quad p = p_0.$$

Заметим, что в силу несмещенности оценки m/n для p нулевую гипотезу можно записать и так:

$$H_0: \quad M\left(\frac{m}{n}\right) = p_0.$$

Другими словами, требуется проверить, значимо или нет отличается частота от значений p_0. В качестве критерия проверки гипотезы примем величину

$$U = \frac{\frac{m}{n} - p_0}{\sqrt{p_0 q_0}} \cdot \sqrt{n}, \qquad \text{где } q_0 = 1 - p_0. \tag{4.30}$$

Соответствующая случайная величина при справедливости гипотезы H_0 имеет стандартное нормальное распределение. При этом рассуждения аналогичны приведенным в п. 8.3 для случая известной дисперсии, с учетом того, что $M\left(\frac{m}{n}\right) = p_0$, $D\left(\frac{m}{n}\right) = \frac{p_0 q_0}{n}$.

В зависимости от конкурирующей гипотезы решающее правило будет таким же, как для случая известной дисперсии, но значение $U_{\text{набл}}$, конечно, следует вычислять по формуле (4.30).

4.15. Критерий согласия Пирсона

Определение 4.18. *Критериями согласия называют критерии для проверки гипотез о виде закона распределения случайной величины.*

Пусть имеется случайная выборка, состоящая из n элементов. Требуется найти закон распределения изучаемой случайной величины ξ (или, как условились говорить, генеральной совокупности), определить его параметры и оценить согласие выборки с принятым законом распределения.

На основании статистического материала проверяется гипотеза H_0, состоящая в том, что случайная величина ξ подчиняется некоторому закону распределения. Для того чтобы принять или отвергнуть гипотезу H_0, рассматривается величина U — степень расхождения теоретического и статистического распределения. За U принимают сумму квадратов (с некоторыми коэффициентами) отклонений теоретических вероятностей P_i от соответствующих относительных частот P_i^* (критерий χ^2).

Схема расчетов с помощью критерия Пирсона (критерия χ^2) следующая.

(1) На основании выборки выбираем в качестве предполагаемого какой–то закон распределения изучаемой величины (например, с помощью гистограммы относительных частот) и оцениваем его параметры, как описано выше.

(2) Все множество наблюдений разбиваем на s интервалов вида $(a_{j-1}; a_j]$ и подсчитываем эмпирические частоты — количество наблюдений m_j, попавших в j-ый интервал (см. п. 7.3).
Относительная частота наблюдений, попавших в j-ый интервал, равна $P_j^* = \dfrac{m_j}{n}$, $\quad (m_1 + \ldots + m_s = n)$, сумма всех относительных частот, очевидно, равна единице.

(3) Определяем теоретические частоты m'_j для j-го интервала $(a_{j-1}; a_j]$:

$$m'_j = \Big(F(a_j) - F(a_{j-1})\Big) \cdot n,$$

где $F(x)$ – теоретическая функция распределения, найденная на этапе 1.

(4) Вычисляем критерий $\chi^2_{\text{набл}}$ (критерий Пирсона):

$$\chi^2_{\text{набл}} = \sum_{j=1}^{S} \frac{(m_j - m'_j)^2}{m'_j}. \tag{4.31}$$

Из этого выражения видно, что $\chi^2_{\text{набл}}$ равно нулю лишь при совпадении всех соответствующих эмпирических и теоретических частот: $m_i = m'_i$ $(i = 1, 2, \ldots, l)$. В противном случае $\chi^2_{\text{набл}}$ отлично от нуля и тем больше, чем больше расхождение между частотами. Величина χ^2, определяемая равенством (4.31), является случайной, и (при больших n) имеет χ^2 — распределение с k степенями свободы (принимается без доказательства).

(5) Определяем число степеней свободы k случайной величины χ^2:

$$k = s - 1 - r, \tag{4.32}$$

где r — число параметров закона распределения (для нормального закона распределения $r = 2$), s — число интервалов.

(6) По заданному уровню значимости α и числу степеней свободы k по таблице критических точек распределения χ^2 (таблица приложения 4) находим критическую точку $\chi^2_{\text{кр}}(\alpha; k)$. Если $\chi^2_{\text{набл}} < \chi^2_{\text{кр}}(\alpha; k)$ — нет оснований отвергнуть гипотезу о принятом (нормальном) законе распределения. Если $\chi^2_{\text{набл}} > \chi^2_{\text{кр}}(\alpha; k)$ — гипотезу отвергают с уровнем значимости α.

Пример 4.12. *С помощью критерия Пирсона проверить гипотезу о нормальном распределении выборки: 2,98; 3,03; 3,17; 3,22; 3,57; 3,59; 3,95; 3,96; 4,03; 4,16; 4,35; 4,47; 4,54; 4,96; 5,01.*

◀Разобьем все множество значений выборки на 6 интервалов, границы которых занесены во второй столбец табл. 4.1.

В третий столбец табл. 4.4 заносим количество наблюдений m_j, попавших в j-ый интервал. По формулам (4.2), (4.12), (4.5) определяем параметры нормального распределения $\bar{x}$ и S^* для выборки из табл. 4.2:

$$\bar{x} = 3,933; \quad S^* = 0,664$$

Таблица 4.1

Решение примера 4.2				
j	a_j	m_j	$F(a_j)$	m'_j
0	2,5	1	0,0155	0,969
1	3,0	3	0,0800	2,659
2	3,5	4	0,2573	4,246
3	4,0	4	0,5404	3,948
4	4,5	2	0,8036	2,137
5	5,0	1	0,9460	0,673
6	5,5		0,9909	

и находим значения теоретической функции распределения $F(a_j)$. В данном примере $F(a_j) = \Phi\left(\dfrac{a_j - \bar{x}}{S^*}\right) + 0{,}5$. В пятый столбец заносим теоретические частоты m'_j, вычисляемые, как указано выше.

По формуле (4.31) находим значение $\chi^2_{\text{набл}} = 0{,}228$. По таблице приложения 4 для $\alpha = 0{,}05$ и $k = 6 - 1 - 2 = 3$ находим критическую точку $\chi^2_{\text{кр}}(0{,}05; 3) = 7{,}8$. Поскольку $\chi^2_{\text{набл}} < \chi^2_{\text{кр}}(0{,}05; 3)$, нет оснований отвергать гипотезу H_0 о нормальном распределении заданной выборки.